

EDA COVID-19 en Estados Unidos

Evolución, patrones y diferencias regionales

Análisis Exploratorio de Datos sobre la evolución epidemiológica en EE.UU. · **Proyecto 5**
– **Bootcamp Data Analytics**

Autores: Ángel Moreno, Manuel Macarro y Yasira Blanco



La pandemia no siguió un único patrón nacional

El COVID-19 impactó a Estados Unidos de forma profundamente desigual. Mientras algunos estados sufrían colapsos sanitarios en primavera de 2020, otros alcanzaban sus picos meses más tarde. Las diferencias en densidad de población, políticas públicas, capacidad hospitalaria y comportamiento social generaron dinámicas regionales muy distintas.

Comprender estos patrones no es solo un ejercicio académico: es la base para tomar mejores decisiones en futuras crisis sanitarias. Este proyecto utiliza técnicas de **Análisis Exploratorio de Datos (EDA)** para revelar esas diferencias con rigor y claridad.

 El EDA permite formular hipótesis, detectar anomalías y comunicar hallazgos antes de construir modelos predictivos.

Factores de desigualdad regional

- Densidad poblacional
Grandes urbes vs. zonas rurales
- Políticas sanitarias
Lockdowns, mascarillas y restricciones
- Capacidad hospitalaria
Recursos UCI y camas disponibles
- Timing de las olas
Diferentes momentos y magnitudes

¿Qué queremos descubrir con este análisis?

El proyecto se articula en torno a un objetivo central: **comprender la evolución temporal del COVID-19 en EE.UU. y detectar diferencias relevantes entre estados**. Para lograrlo, se definen cinco objetivos específicos que guían todo el análisis.



Evolución temporal

Analizar la progresión de casos, hospitalizaciones y fallecimientos a lo largo del tiempo.



Comparativa estatal

Identificar diferencias entre estados en intensidad, timing y mortalidad.



Detección de olas

Reconocer los periodos de aceleración, pico y estabilización pandémica.



Anomalías del reporting

Detectar inconsistencias, valores negativos y errores administrativos en los datos.



Relaciones entre indicadores

Explorar correlaciones entre positividad, hospitalizaciones y mortalidad.

El dataset: *all-states-history.csv*

El análisis se basa en datos históricos del **COVID Tracking Project**, que recopiló información diaria de todos los estados de EE.UU. desde marzo de 2020. El fichero contiene más de 20.000 registros con variables epidemiológicas clave.


✅ Cobertura geográfica: los 50 estados + DC. Cobertura temporal: marzo 2020 – marzo 2021.

La granularidad diaria por estado permite tanto el análisis agregado nacional como comparativas regionales detalladas.

Variables clave del dataset

Variable	Descripción
date	Fecha del registro (diario)
state	Código del estado (2 letras)
positive	Casos positivos acumulados
death	Fallecimientos acumulados
hospitalizedCurrently	Hospitalizados en el día
totalTestResults	Tests realizados acumulados
positiveIncrease	Nuevos casos diarios
deathIncrease	Nuevas muertes diarias

El COVID evolucionó en múltiples olas claramente diferenciadas



Ola 1 — Primavera 2020

Epicentro en Nueva York. Colapso hospitalario inicial.

Ola 2 — Verano 2020


Expansión al Sur y Oeste. Florida, Texas y California lideran.

Ola 3 — Otoño-Invierno

La más devastadora en número de casos y fallecimientos a nivel nacional.

No todos los estados vivieron la pandemia igual

La comparativa entre los cuatro estados más poblados revela dinámicas temporales radicalmente distintas. Nueva York concentró el impacto inicial, mientras que Florida, Texas y California alcanzaron sus picos en oleadas posteriores, con diferentes niveles de mortalidad relativa.



En este gráfico podemos observar que en **California** fue donde hubo el **mayor** incremento de casos de contagiados de **COVID-19**.

📄 California experimentó su pico más tardío (enero 2021), mientras que Nueva York fue el epicentro de la primera ola. Cada estado requiere un análisis temporal propio.

El impacto epidemiológico en cifras

29M

Casos confirmados

Total de positivos registrados en EE.UU. hasta marzo 2021

530K

Fallecimientos

Muertes atribuidas al COVID-19 en el periodo analizado

400M


Tests realizados

Pruebas diagnósticas totales registradas en el dataset

1.8%


Tasa de mortalidad

Fallecimientos sobre casos confirmados a nivel nacional




Positividad máxima

Tasa de positividad en el peor momento de la tercera ola



Reducción de casos


Caída de nuevos casos desde el pico de enero a marzo 2021



Nulos en hospitalización

Proporción media de valores faltantes en esa variable

La positividad puede anticipar un empeoramiento sanitario




El análisis de correlación entre variables epidemiológicas revela patrones de comportamiento que podrían tener valor predictivo:

Positividad →
Hospitalizaciones

Un aumento sostenido en la tasa de positividad precede en 7–14 días el incremento de hospitalizaciones.

Hospitalizaciones →
Fallecimientos

La mortalidad sigue con un retraso de 10–21 días al pico de hospitalización.



i Más pruebas realizadas reducen artificialmente la tasa de positividad — el volumen de testing debe considerarse siempre en la interpretación.

Los datos reales contienen errores y deben validarse

Tipos de anomalías detectadas

Valores negativos

Incrementos diarios negativos en `positiveIncrease` y `deathIncrease`, indicativos de correcciones retroactivas masivas.

Picos artificiales

Acumulación de casos no reportados durante fines de semana, publicados en bloque los lunes, generando picos artificiales.

Reclasificaciones

Algunos estados reclasificaron casos probables como confirmados en fechas concretas, distorsionando las series temporales.

Impacto en el análisis

Solución aplicada


Media móvil de 7 días para suavizar las distorsiones del reporting semanal y obtener tendencias fiables.

Criterio de exclusión

Valores negativos extremos marcados como anomalías y excluidos de los cálculos de tendencia, pero conservados en los datos brutos.


 Un solo valor anómalo sin tratar puede sesgar completamente una media o correlación.

Cuatro insights que definen el análisis




Evolución desigual entre estados

Cada estado siguió su propio ritmo pandémico. Los picos, la duración de las olas y la intensidad del impacto variaron significativamente según la región y el momento.



La positividad como señal temprana

La tasa de positividad se comportó como un indicador adelantado. Su aumento sostenido anticipaba en días el incremento de hospitalizaciones y, posteriormente, de fallecimientos.



Más contagios ≠ más mortalidad

Estados con alto número de casos no siempre registraron las tasas de mortalidad más elevadas. La capacidad hospitalaria y la demografía jugaron un papel determinante.

La validación del proceso: 3 pasos




El reporting requiere validación

Las anomalías detectadas demuestran que los datos epidemiológicos en tiempo real contienen errores sistemáticos. Validar antes de analizar es una fase imprescindible del proceso.

LIMITACIONES

¿La letalidad disminuyó con el tiempo?



Grados de letalidad


- La **letalidad en 2020** es mas elevada en **Marzo** donde empieza a disminuir
- Coincide con la **tasa de hospitalización** hasta el punto que vemos que empieza a **disminuir** también la **letalidad**
- Pero vemos como las **hospitalizaciones empiezan a aumentar**.

Los estados más resilientes tras un pico


Observamos la duración de los picos más fuertes de contagios

 **Arizona** el más afectado

 **Alaska** el que menos




Predicción de olas



- 1 — Los estado **no experimentaron** las olas de COVID con la misma intensidad ni en el mismo momento.
- 2 — **New York** presenta un pico muy fuerte al inicio de la pandemia, asociado a la **primera gran ola** de 2020.
- 3 — **Texas** y **Florida** muestran picos más importantes en etapas posteriores.
- 4 — La **media móvil de 7 días** permite identificar mejor las tendencias reales eliminando el ruido diario.

Variables que anticipan mejor un empeoramiento



- **Tasa de positividad** suele aumentar antes que las hospitalizaciones.
- Los casos positivos muestran **crecimiento rápido** tras el incremento de la positividad.
- Las hospitalizaciones reaccionan con cierto retraso respecto al **aumento de casos**.
- Este patrón sugiere un **efecto lead-lag** entre variables epidemiológicas.

CONCLUSIONES

Conclusión

El COVID-19 no evolucionó de forma uniforme en Estados Unidos. A través del EDA fue posible detectar diferencias entre estados, patrones temporales relevantes y limitaciones propias de los datos.

Demostrando cómo el análisis exploratorio puede generar conocimiento útil incluso antes de aplicar modelos predictivos.

